투구 트래킹 시계열 기반 투수 부상 조기 경보

MLB Statcast 2021–2026 정규시즌

2026.10.27

데이터사이언스전공
김소연 · 정민서 · 강동한 · 최민석

목차

Contents

01 연구 배경 문제 정의 , 투수 부상 현황 , 시계열로 보는 이유 **p. 3–4**

02 선행 연구 4 개 주제의 관련 연구 , 한계와 본 연구의 차별점 **p. 5–8**

03 데이터 MLB Statcast 2021–2026, 분석 단위와 변수 **p. 9–10**

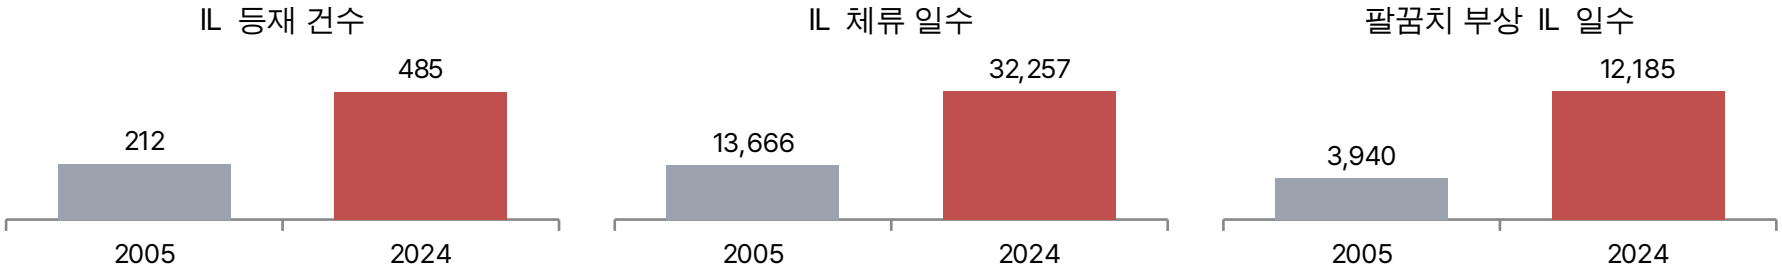
04 방법론 연구 질문 , 프레임워크 , 분할 · 모델 · 평가 **p. 11–13**

05 EDA 구속 추세 , 부상 부위 , IL 직전 구속 · 회전수 변화 **p. 14–18**

연구 배경

문제 정의 : 무엇을 , 왜 분석하는가

분석 목표 투수별 등판 단위 구속 · 구속 변동성 · 릴리스 포인트 시계열에서 ' 평소와 다른 변화 ' 를 감지해 , 팔 부상으로 IL 에 오르기 전에 경보를 낸다



MLB 투수 부상 추이 , 2005 년 vs 2024 년 (AP 보도)

- IL 등재 **212 건 → 485 건** , IL 체류 일수 **13,666 일 → 32,257 일** . 팔꿈치 부상 IL 일수는 약 **3 배** (3,940 → 12,185 일)
- 2015–2025 년 어깨 · 팔꿈치 부상 : 투수 **1,122 명** , IL 등재 **2,365 건** , 급여 손실 약 **33 억 3,000 만 달러** (Dillon et al., OJSM)
- 부상이 확인되면 이미 손실이 생긴 뒤다 . 핵심은 ' 누가 위험한가 ' 보다 **' 언제 쉬게 할 것인가 '**
- 징후를 미리 잡으면 등판 간격 조정 , 투구 부하 관리 , 휴식 부여를 검토할 수 있다

연구 배경

왜 시계열 분석에 맞는가

자기상관

- 신호는 투수 자신의 과거 대비 편차로만 정의된다
- 등판 순서를 무작위로 섞으면 신호가 사라진다
- 과거로 다음 값을 예측하고 그 잔차를 감시할 수 있다

추세

- ' 구속 혁명 ' 으로 리그 포심 평균이 꾸준히 오른다
- 93.69 → 94.77 mph (2021→2026), 6 시즌 동안 한 번도 꺾이지 않고 +1.08
- 개인의 이상을 판단할 때 반드시 제거할 성분

계절성

- 구속은 시즌 초보다 후반에 높다
- 2025 년 4 월 94.18 → 6 월 94.61 mph 후 평평 (2024 년 : 94.04 → 94.40)
- 부상 발생 자체도 특정 시기에 몰린다

외생 변수

- 등판 간격
- 최근 7·14·28 일 누적 투구 수 , ACWR
- 휴식 · 부하로 설명되는 변화를 부상 신호와 구분한다

➡ **투수의 평소 수준을 예측할 수 있다면 , 거기서 벗어난 정도가 곧 경고가 된다**

→ 수업에서 다루는 ARIMA / ARIMAX, EWMA, 잔차 기반 이상 탐지와 바로 연결된다

선행 연구

(1) 구속 - 부상 연관 · 평소 vs 부상 직전

연구	대상 · 방법	핵심 결과	한계 (우리와의 차이)
주제 1. 구속이 부상과 연관되어 있다는 전제를 뒷받침하는 연구			
Prodromo 외 (2016)	UCLR 투수 vs 같은 나이 대조군 (2002–2015) 사례 - 대조 , 조건부 로지스틱 회귀	수술 전 시즌 평균 구속이 더 높았고 , 속구 평균 구속이 유의한 변수	투수끼리 비교 , 시즌 평균 사용 → 변화 시점을 알 수 없음
주제 2. 투수의 평소 모습과 부상 직전을 비교한 연구			
Mastroianni 외 (2026)	UCL 수술 투수 78 명 vs 매칭 대조군 156 명 투수 내 변화 분석	마지막 5 등판 구속 점진 하락 (P = .019), 수평 릴리스 변동성 큼 (P = .005)	사후 분석 , AUC· 선행 일수 미보고
Ozaki (2026, 석사논문)	UCLR 투수 46 명 (2016–2024) 오토인코더 이상 탐지	부상이 가까울수록 이상 정도 2.7 배 . 코드와 매칭 대조군 45 쌍 공개	건강한 투수도 경보 (73% vs 66%), 시간 순서를 일부러 무시

➡ **구속은 부상과 연관되고 부상 직전 평소와 달라지지만 , 이를 경보로 바꿔 오경보까지 평가한 연구는 없다**

선행 연구

(2) 시계열 방법 · 외생 변수

연구	대상 · 방법	핵심 결과	한계 (우리와의 차이)
주제 3. 시계열 방법을 쓴 연구			
Mayo 외 (2021)	UCLR 투수 223 명의 수술 전 15 경기 Mann-Kendall 추세검정	포심 구속 경기당 약 0.1 mph 하락 (tau = −0.657, P < .001), 회전수 경기당 약 5 rpm 감소	건강한 대조군 없음 , 경보 규칙 없음
Bright 외 (2026)	중계 영상으로 3 차원 자세 추정 투수 7,348 명 선별	토미 존 수술 AUC 0.811, 중증 팔 부상 AUC 0.825	영상 추정값 사용 , 시점별 선별 모형 (개인 시계열 경보 아님)
주제 4. 외생 변수 관련 연구			
Slowik 외 (2021)	대학 투수 17 명 ACWR, ROC 로 기준 선정	ACWR 이 ±33% 넘게 변하면 다음 주 부상 위험 8.3 배	표본이 작음 (95% CI 1.8–54.1), 만성 구간 3 주

➡ **부상 전 하락 추세는 확인됐지만 경보 규칙은 없고 , 투구 부하 (ACWR) 는 함께 볼 외생 신호다**

선행 연구

선행 연구의 한계

한계 1

시즌 평균으로 부상 투수와 건강한 투수를 비교

필요

투수 개인의 시계열을 기준으로 변화를 읽어야 한다

한계 2

추세 검정에 그쳐 경보 규칙과 오경보 집계가 없음

필요

선행 시간과 오경보로 평가하는 경보 시스템이 필요하다

한계 3

느린 하락이 기준선에 흡수될까봐 시계열 모델을 피함

필요

한 걸음 앞 예측의 잔차를 감시하면 기준선이 따라가도 신호가 남는다

선행 연구

본 연구의 차별점 (Novelty)

핵심 아이디어 투수별 시계열 기준선 : 자기 과거로 예측한 기대 구속과 실제 구속의 차이 (잔차) 를 감시한다

1. 공개 데이터 기반 다변량 시계열

성능 지표 구속 · 변동성 · 릴리스

부하 지표 등판 간격 · 누적 투구 수 · ACWR

누구나 접근할 수 있는 Statcast 와 MLB 기록만 사용
→ 재현 가능한 결론

2. 통계 검정을 넘어 실제 경보 시스템 평가

얼마나 일찍 ? IL 등재 며칠 전에 울리는가

얼마나 자주 헛울리나 ? 오경보 빈도

조사한 선행 연구 중 선행 일수와 오경보 빈도를 함께 보고한 사례는 없다

데이터

데이터셋 : MLB Statcast (2021–2026)

❑ 출처 (Sources)

- ❑ 투구 데이터 : Baseball Savant **Statcast**, 투구 단위
- ❑ 부상 레이블 : **MLB 공식 API 거래 기록** (IL 등재일, 부상 부위)
- ❑ 기온 : MLB API 경기별 날씨, 필요하면 Open-Meteo 로 보완

❑ 데이터 정보 (Data info)

항목	내용
기간	2021–2026 정규시즌 (6 시즌). 2017 년 구속 정의 변경 ·2020 년 Hawk-Eye 전환 이후 구간
규모	투구 약 438 만 개 · 시즌당 투수 855–909 명 · IL 등재 3,340 건 (팔 관련 1,683 건)
빈도	투구를 투수 × 등판 단위로 집계 (등판 간격은 불규칙)
핵심 변수	구속, 릴리스 좌우 · 높이, 익스텐션, 회전수, 구종, 투수, 날짜, 경기 번호
외생 변수	등판 간격, 최근 7·14·28 일 누적 투구 수, ACWR

- ❑ **연구 적합성** : 길고 공개된 투구 단위 시계열이 실제 부상 레이블과 연결되어, 경보가 실제 결과와 맞았는지 검증할 수 있다

데이터

분석 단위와 변수

그룹	변수	정의
투구 지표	구속	등판 내 패스트볼 평균 · 최고 구속
	구속 변동성	등판 내 패스트볼 구속의 표준편차
	릴리스 포인트	수평 · 수직 릴리스 위치의 평균과 표준편차
	보조	회전수 , 익스텐션 , 경기 내 구속 하락 기울기
부하 지표	등판 간격	직전 등판 이후 일수
	최근 투구량	최근 7·14·28 일 누적 투구 수
	ACWR	7 일 평균 ÷ 28 일 평균 투구량

- **분석 단위** : 투수 × 등판 . 시간축 = 등판 순번 , 등판 간격은 별도 변수
- **부상 사건** : 팔 관련 사유로 IL 등재
- IL 기록은 **평가에만** 쓰고 , 학습에는 쓰지 않는다

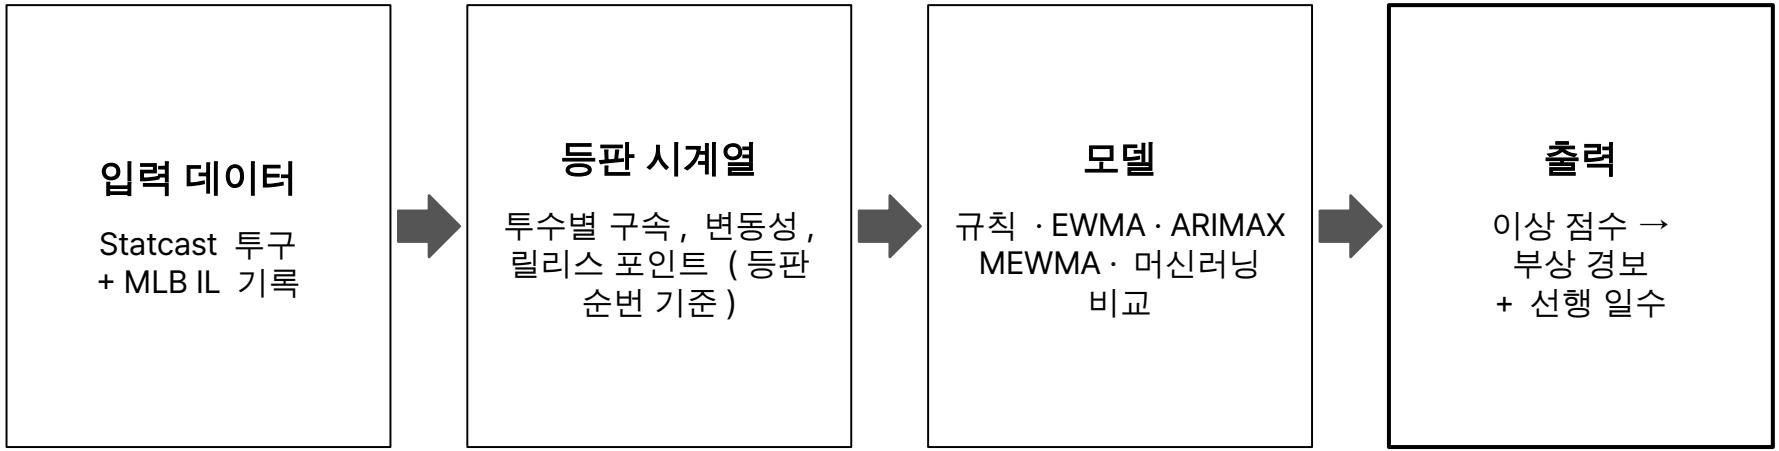
방법론

연구 질문 (RQ)

RQ1	투수 자신의 과거로 예측한 구속과 실제 구속의 차이 (잔차) 로 팔 부상 IL 등재를 얼마나 일찍 , 얼마나 정확하게 감지할 수 있는가 ?
RQ2	부상 직전 몇 차례 등판에서 구속 , 구속 변동성 , 릴리스 포인트는 투수 자신의 평소 수준과 다르게 움직이는가 ?
RQ3	등판 간격 , 최근 7·14·28 일 누적 투구 수 같은 부하 지표를 더하면 경보 성능이 좋아지는가 ?
RQ4	강속구 투수와 그렇지 않은 투수 사이에 경보 신호의 강도가 다른가 ?

방법론

프레임워크



외생 변수 X: 등판 간격 · 최근 7·14·28 일 누적 투구 수 · ACWR

경보 성공 IL 등재일 이전 직전 3 회 등판 (약 21 일) 안에 경보. 2·5 회 등판으로도 평가해 검증 구간에서 확정

방법론

데이터 분할 · 모델 · 평가 지표

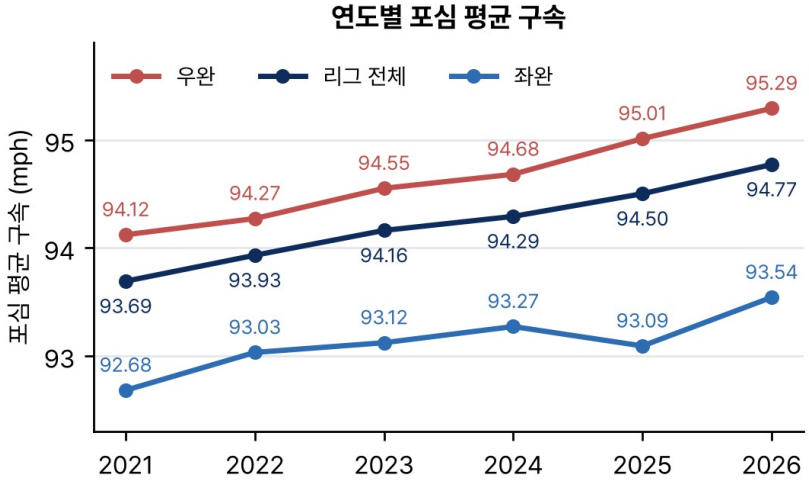
시간 순서 분할	학습 2021–2024	검증 2025 (임계값 결정)	테스트 2026

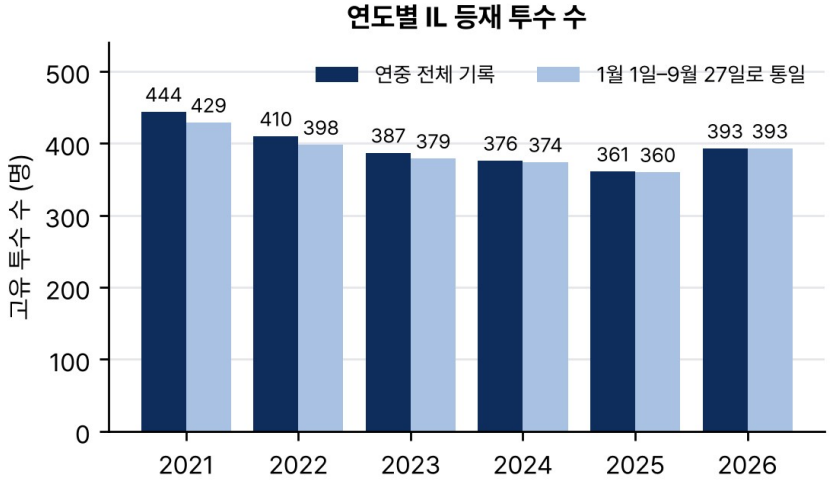
구분	모델	설명
비교 기준선	1. 무작위 점수	우연 수준
	2. 단순 규칙	평소보다 구속이 X mph 이상 떨어지면 경보
	3. 부하 규칙	ACWR 이 ±33% 를 벗어나면 경보
시계열	4. EWMA	표준화 구속의 점진적 하락을 누적 탐지
	5. ARIMAX	휴식일 · 누적 투구 수를 반영한 기대 구속 대비 잔차
추가 검증	6. 머신러닝 방법	시계열 구조를 쓰지 않는 방법과 같은 기준으로 비교
확장	7. MEWMA	구속 · 변동성 · 릴리스를 동시에 감시 (다변량)

질문	지표
정확도	오경보를 투수 - 시즌당 1 회 이하로 둘 때 재현율 · 정밀도 (주 지표 F1)
오경보	투수 - 시즌당 오경보 횟수 , 대조군 경보율
조기성	첫 경보 → IL 등재 선행 일수 (중앙값 · 분포)
전체 성능	등판 단위 AUPRC
참고	구속 예측 오차 MAE, RMSE

탐색적 데이터 분석 (EDA)

(1) 리그 구속 추세와 IL 규모



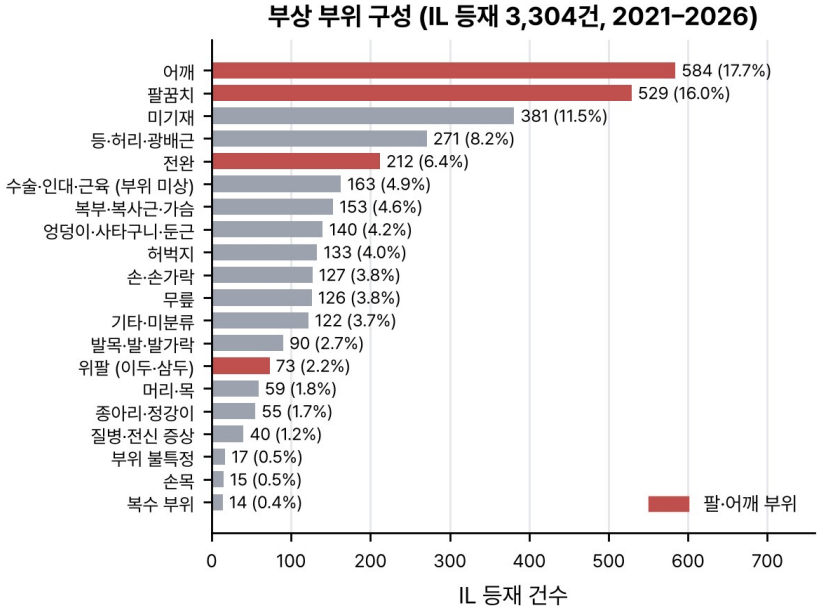


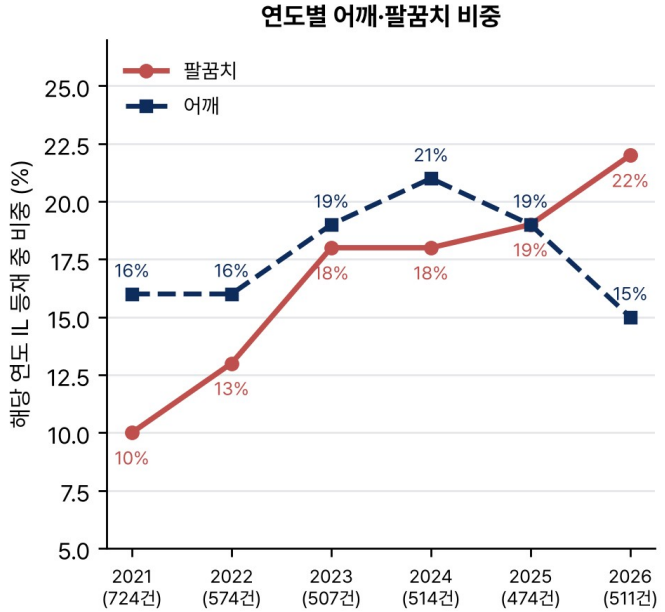
연도별 포심 평균 구속 (투구 가중 평균, 왼쪽)과 IL 등재 고유 투수 수 (오른쪽), 2021–2026

- 리그 포심 구속이 6 시즌 연속 상승 : **93.69 → 94.77 mph** (+1.08) → 추세를 뺀 투수별 기준선이 필요
- IL 등재 투수는 연 **360–444 명** . 2026 년 기록은 9 월 27 일까지라 같은 기간으로 맞춰도 확인 (규모 확인용, 부상률 비교 아님)

탐색적 데이터 분석 (EDA)

(2) 부상 부위 구성





어깨 · 팔꿈치

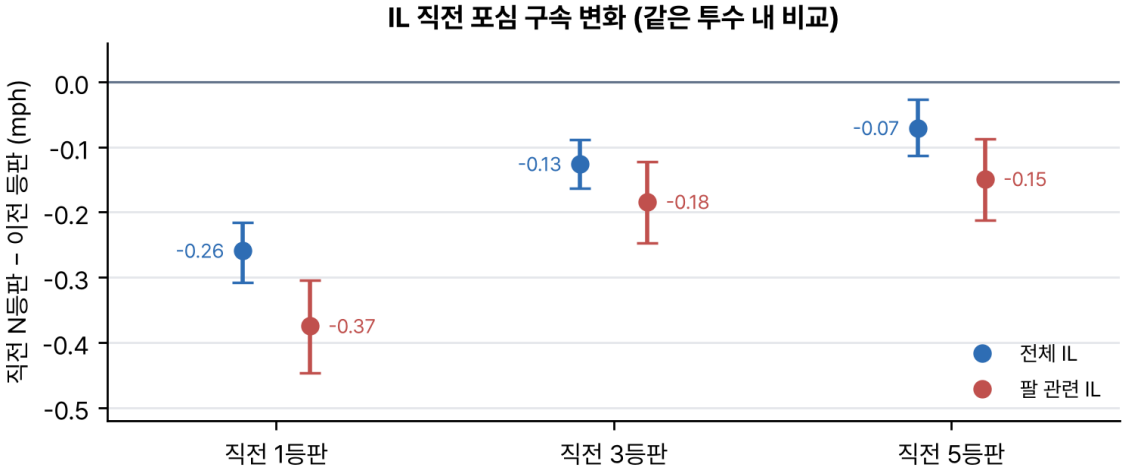
33.7%

전체 IL 등재 중 (584 + 529 건)

- 어깨 17.7%, 팔꿈치 16.0%, 전완 6.4% 로 팔 부위가 가장 큰 비중 (분모는 IL 등재 건수 , 고유 투수 수 아님)
- 팔꿈치 비중이 **10% (2021) → 22% (2026)** 로 증가 → 팔 관련 IL 을 주 분석 사건으로 정의

탐색적 데이터 분석 (EDA)

(3) IL 직전 구속 변화



사건 수	전체 IL	팔 관련
직전 1 등판	1,479	663
직전 3 등판	1,066	460
직전 5 등판	786	329

직전 1 등판 − 이전 등판

전체 IL −0.26 mph

[95% CI −0.31, −0.22]

팔 관련 −0.37 mph

[95% CI −0.45, −0.30]

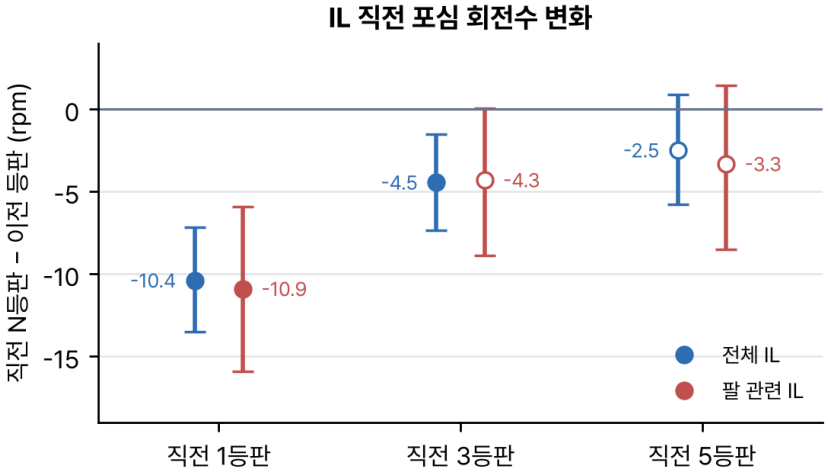
같은 투수의 현재 IL 구간 안에서 직전 N 등판 평균 − 그 이전 등판 평균 (점: 차이, 선: 95% CI, 선수 단위 부트스트랩 2,000 회)

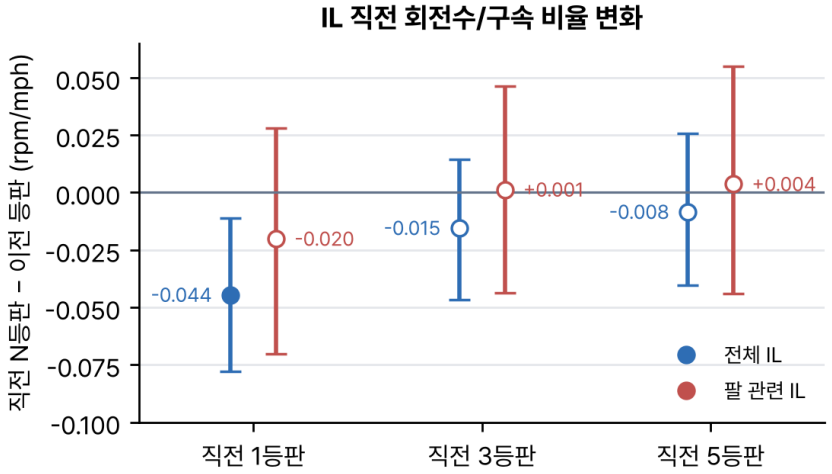
- **같은 투수 내부 비교**다. 건강한 투수 집단과의 비교가 아니다
- 직전 1 등판에서 가장 크게 떨어지고, N 이 커질수록 차이가 줄어든다. 팔 관련 IL 이 모든 구간에서 더 크게 하락

➡ 하락은 IL 직전에 몰린다 → 경보창은 짧게 (직전 3 등판 기준, 2·5 등판으로 확인)

탐색적 데이터 분석 (EDA)

(4) IL 직전 회전수와 회전수 / 구속 비율



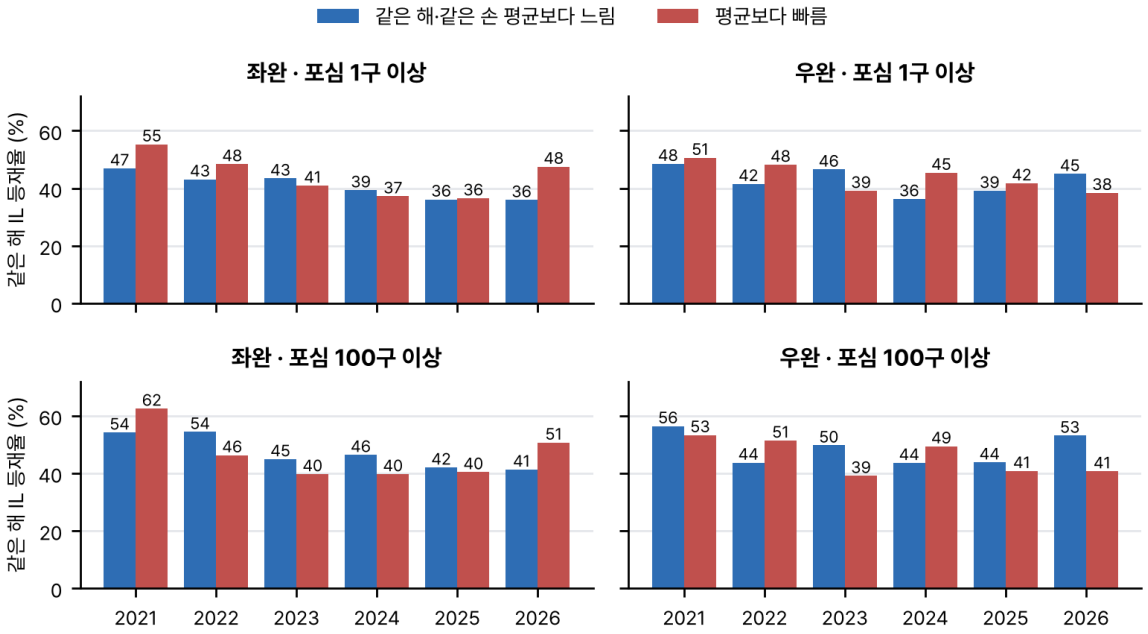


직전 N 등판 - 이전 등판 (같은 투수 내부 비교). 채운 점 = 95% CI 가 0 을 포함하지 않음, 빈 점 = 0 을 포함

- 회전수 : 직전 1 등판 약 **– 10 rpm** (전체 – 10.4, 팔 관련 – 10.9). 5 등판으로 넓히면 95% CI 가 0 을 포함
- 회전수 / 구속 비율 : 전체 IL 의 직전 1 등판만 0 보다 작고 (−0.045), 팔 관련 IL 은 모든 구간에서 0 을 포함

탐색적 데이터 분석 (EDA)

(5) 구속 집단별 같은 해 IL 등재율



같은 해 · 같은 투구손 평균보다 빠른 투수 (빨강) 와 느린 투수 (파랑) 의 같은 해 IL 등재율

- 투수 집단끼리 비교 : 연도 · 투구손별 평균 구속보다 빠른가 느린가
- 빠른 집단이 더 높은 경우는 **24 개 조합 중 12 개** . 방향이 일관되지 않다